

Modelagem Espacial de Dinâmicas de Doenças Infecciosas via Autômatos Celulares: Um Estudo com os Modelos SIR, SIS e SEIR Calibrados para Influenza Sazonal

Alana Barbalho Camara Lins^{1,*}

¹Universidade Federal Rural de Pernambuco (UFRPE), Departamento de Ciência da Computação, Recife, PE, Brasil

*alana.lins@ufrpe.br

ABSTRACT

Modelos compartimentais clássicos assumem mistura homogênea entre indivíduos, o que pode não refletir adequadamente a estrutura espacial do contato infeccioso. Este trabalho descreve um simulador de autômato celular (AC) de código aberto que embute os modelos SIR, SIS e SEIR em uma grade toróide 80×80 , com regras de transição probabilísticas locais derivadas das equações compartimentais correspondentes. O simulador foi calibrado para influenza sazonal ($\beta = 0,18$, $\gamma = 0,14$, $\sigma = 0,50$) e utilizado em cinco experimentos controlados, cada um com $n = 30$ réplicas Monte Carlo. Os resultados mostram que o número de reprodução sob as hipóteses do modelo espacial, $R_0^{AC} = [1 - (1 - \beta)^k] / \gamma$, difere substancialmente do valor de campo médio $R_0^{ODE} = \beta / \gamma$ para os mesmos parâmetros — em $\beta = 0,10$, por exemplo, $R_0^{ODE} = 0,71$ (subcrítico) enquanto $R_0^{AC} = 4,07$, com taxa de ataque observada de 98,7%. A topologia de Moore (8 vizinhos) produziu pico 48% superior ao de Von Neumann (4 vizinhos); o SEIR reduziu o pico em 71% e o atrasou em 96 passos em relação ao SIR; e a prevalência de pico decresceu com o tamanho da grade, comportamento não capturado pelas EDOs. Os padrões geométricos das frentes de onda são consistentes com a dimensão de similaridade dos AC discutida por Wolfram. O código-fonte está disponível publicamente (ver *Disponibilidade de Código*).

Introdução

Desde o trabalho seminal de Kermack e McKendrick¹, os modelos compartimentais baseados em equações diferenciais ordinárias (EDO) têm sido a ferramenta dominante na modelagem matemática de doenças infecciosas. Arcabouços como SIR, SIS e SEIR oferecem tratabilidade analítica e boas propriedades assintóticas, mas pressupõem mistura homogênea: qualquer suscetível pode entrar em contato com qualquer infeccioso com igual probabilidade. Essa hipótese é conveniente, mas frequentemente não se sustenta em populações reais, onde a transmissão depende da proximidade física entre indivíduos².

Os autômatos celulares (AC) oferecem uma abordagem alternativa na qual a estrutura espacial é explícita por construção. Um AC é definido por uma quádrupla (L, Q, V, δ) — grade discreta L , conjunto finito de estados Q , vizinhança V e regra de transição síncrona δ — e produz dinâmicas coletivas a partir de interações estritamente locais^{3,4}. Wolfram³ mostrou que mesmo regras elementares geram estruturas espaciais autossimilares cuja *dimensão de similaridade* depende da geometria da vizinhança; padrões análogos aparecem nas frentes de onda epidêmicas simuladas neste trabalho.

A influenza sazonal foi escolhida como caso de referência por dispor de parâmetros bem caracterizados: período de incubação de aproximadamente 2 dias, período infeccioso médio de 7 dias e R_0 mediano estimado em 1,28⁵. Estudos anteriores com AC epidemiológicos^{6,7} já indicaram que a estrutura espacial altera tanto as estimativas de R_0 quanto a geometria das ondas de propagação; contudo, a comparação sistemática entre tipos de vizinhança e a quantificação da variabilidade estocástica via Monte Carlo permanecem pouco exploradas nesse contexto.

Este trabalho contribui com: (i) um simulador Python modular e vetorizado que implementa SIR, SIS e SEIR em uma grade 2D toróide; (ii) a formulação do número de reprodução espacial R_0^{AC} válido sob as hipóteses do modelo, incluindo análise do comportamento de saturação em $1/\gamma$ quando $\beta \rightarrow 1$; e (iii) cinco experimentos com varredura de parâmetros, cada um com 30 réplicas independentes, tornando os resultados reprodutíveis.

Resultados

Taxa de transmissão β

Com $\gamma = 0,14$, $N = 80^2$, $I_0 = 5$ e vizinhança de Moore, β foi variado entre 0,10 e 0,70 (Tabela 1). O aumento de β reduziu o passo do pico de $t \approx 59$ para $t \approx 19$ (−68%) e elevou a magnitude do pico de 748 ± 115 para 1.937 ± 192 infectados simultâneos (+159%), padrão esperado e consistente com a literatura². Em $\beta = 0,10$, $R_0^{ODE} = 0,71$ indica extinção pela teoria de campo médio, mas a taxa de ataque observada foi de 98,7% — comportamento explicado por $R_0^{AC} = 4,07$ sob a vizinhança de Moore. Os valores de R_0^{AC} convergem para $1/\gamma = 7,14$ conforme β aumenta, refletindo a saturação da probabilidade de infecção $P = 1 - (1 - \beta)^k \leq 1$.

Table 1. Efeito de β na dinâmica epidêmica ($\gamma = 0,14$, Moore, SIR, $N = 80^2$, $n = 30$). Média $\pm$ d.p.

β	R_0^{ODE}	R_0^{AC}	Pico infectados	Passo do pico
0,10	0,71	4,07	748 ± 115	59 ± 13
0,18 [†]	1,29	5,68	1.236 ± 175	33 ± 4
0,30	2,14	6,73	1.631 ± 179	24 ± 3
0,50	3,57	7,11	1.870 ± 198	20 ± 3
0,70	5,00	7,14	1.937 ± 192	19 ± 3


[†]Cenário de referência (influenza sazonal)⁵. $R_0^{ODE} = \beta/\gamma$; $R_0^{AC} = [1 - (1 - \beta)^8]/\gamma$.

Topologia da vizinhança


Sob $\beta = 0,30$ e $\gamma = 0,05$, a vizinhança de Moore ($k = 8$; Figura 1) produziu pico 48% superior ao de Von Neumann ($k = 4$) — 3.154 ± 180 vs. 2.132 ± 190 — e antecipou o pico em 21 passos (Tabela 2). A redução na duração total foi modesta (6%). Esses resultados são esperados: a probabilidade máxima de infecção por passo é $1 - 0,70^8 = 0,942$ para Moore contra $1 - 0,70^4 = 0,760$ para Von Neumann, de modo que maior conectividade local acelera a propagação⁷. As geometrias das frentes de onda são igualmente distintas: Von Neumann gera frentes em diamante (métrica de Manhattan), Moore gera frentes aproximadamente circulares (métrica de Chebyshev), padrões coerentes com as propriedades de simetria de cada vizinhança.

Table 2. Efeito da topologia de vizinhança ($\beta = 0,30$, $\gamma = 0,05$, SIR, $N = 80^2$, $n = 30$). Média $\pm$ d.p.

Vizinhança	k	Pico infectados	Passo do pico	Duração (passos)
Von Neumann	4	2.132 ± 190	52 ± 6	230 ± 28
Moore	8	3.154 ± 180	31 ± 3	215 ± 29



(a) Von Neumann



(b) Moore

Figure 1. Tipos de vizinhança implementados no autômato celular. A célula central (C, preta) representa o indivíduo de referência; as células em laranja são seus vizinhos diretos, considerados no cálculo da probabilidade de infecção $P = 1 - (1 - \beta)^k$. Von Neumann ($k = 4$) restringe o contato aos quatro vizinhos ortogonais, produzindo frentes de onda com geometria de diamante; Moore ($k = 8$) inclui as diagonais e gera frentes aproximadamente circulares.

Estrutura do modelo compartimental

Com $\beta = 0,30$, $\gamma = 0,05$, $\sigma = 0,08$ e Moore, os três modelos produziram regimes qualitativamente distintos (Tabela 3). O SIS manteve um estado endêmico persistente com prevalência simultânea de 95,7% (6.125 ± 7): sem imunidade permanente,

suscetíveis recuperados retornam ao estado S e a infecção circula indefinidamente. O SEIR reduziu o pico em 71% (908 ± 108) e o atrasou em 96 passos em relação ao SIR, corroborando o efeito amortecedor do período latente já documentado na literatura^{8,9}. Do ponto de vista prático, essa redução indica que doenças com período de incubação expressivo exercem pressão instantânea menor sobre o sistema de saúde, mesmo que o total acumulado de casos seja semelhante ao do SIR.

Table 3. Comparação entre modelos compartimentais ($\beta = 0,30$, $\gamma = 0,05$, $\sigma = 0,08$, Moore, $N = 80^2$, $n = 30$). Média $\pm$ d.p.

Modelo	Pico infectados	Passo do pico	S (final)	Regime
SIR	3.154 ± 180	31 ± 3	0 ± 0	Transitório
SIS	6.125 ± 7	199 ± 95	336 ± 17	Endêmico
SEIR	908 ± 108	127 ± 17	0 ± 0	Transitório com atraso

Tamanho da grade

Mantendo $\beta = 0,30$, $\gamma = 0,05$ e $I_0 = 5$, a prevalência de pico decresceu de $65,8 \pm 3,5\%$ a $40,9 \pm 2,8\%$ ao aumentar a grade de 40^2 a 120^2 (Tabela 4). O mecanismo é geométrico: em domínios menores, a frente iniciada por cinco células infectadas satura a população antes de declinar; em domínios maiores, a frente percorre distâncias proporcionalmente maiores, reduzindo a sobreposição simultânea. As EDOs produzem curvas normalizadas idênticas independentemente de N , de modo que esse efeito de densidade é uma propriedade específica do modelo espacial.

Table 4. Efeito do tamanho da grade na prevalência de pico ($\beta = 0,30$, $\gamma = 0,05$, $I_0 = 5$, Moore, SIR, $n = 30$). Média $\pm$ d.p.

Grade	N	Pico I (%)
40×40	1.600	$65,8 \pm 3,5$
60×60	3.600	$57,5 \pm 3,0$
80×80	6.400	$49,3 \pm 2,8$
100×100	10.000	$44,0 \pm 3,2$
120×120	14.400	$40,9 \pm 2,8$

Número inicial de infectados

Variar I_0 de 1 a 50 antecipou o pico em 36 passos ($t = 49 \rightarrow t = 13$) e elevou sua magnitude em 57% ($2.867 \pm 42 \rightarrow 4.503 \pm 140$). Com mais focos iniciais, múltiplas frentes de infecção se expandem simultaneamente, acelerando o crescimento efetivo nas fases precoces. A implicação prática é que intervenções de detecção e isolamento que reduzam I_0 de 10 para 1 podem atrasar o pico em cerca de 26 passos e reduzir sua magnitude em torno de 20%, embora essas estimativas devam ser interpretadas dentro das limitações do modelo.

Discussão

O ponto de maior interesse metodológico deste trabalho é a diferença entre R_0^{ODE} e R_0^{AC} para os mesmos parâmetros. Sob as hipóteses do modelo — grade regular, vizinhança fixa, população estática —, o número de reprodução espacial pode ser expresso como:

$$R_0^{AC} = \frac{1 - (1 - \beta)^k}{\gamma} \quad (1)$$

que representa o número esperado de novas infecções geradas por um único infeccioso durante seu período de infecção em uma grade com k vizinhos fixos. Essa expressão é válida especificamente sob as condições aqui adotadas e não deve ser generalizada para estruturas de contato heterogêneas ou com mobilidade.

Para vizinhança de Moore ($k = 8$), R_0^{AC} tende a $1/\gamma$ conforme $\beta \rightarrow 1$, pois $P = 1 - (1 - \beta)^k$ é limitado por 1. Essa saturação é qualitativamente distinta da relação linear $R_0^{ODE} = \beta/\gamma$ e tem implicação direta para calibração: usar estimativas clínicas de R_0 para definir β sem considerar a geometria da grade produz parâmetros inconsistentes. A calibração adequada requer inverter $1 - (1 - \beta)^k = R_0^{alvo} \cdot \gamma$ numericamente.

As frentes de onda epidêmicas apresentaram geometrias coerentes com a métrica de cada vizinhança — diamante para Von Neumann, circular para Moore —, correspondência análoga à descrita por Wolfram³ para AC elementares, nos quais a

dimensão de similaridade dos padrões autossimilares reflete a topologia local. No contexto epidemiológico, isso sugere que a escolha da vizinhança influi não apenas na velocidade de propagação, mas também na forma da frente e, por consequência, no ritmo de saturação espacial da epidemia.

Limitações

O modelo é intencionalmente simplificado e suas conclusões devem ser interpretadas dentro desse escopo. Os indivíduos são estáticos em uma grade regular, sem qualquer forma de mobilidade, o que é particularmente restritivo dado que o deslocamento humano é um dos principais mecanismos de difusão geográfica de epidemias². A população é homogênea: não há estrutura etária, diferenças de suscetibilidade, imunidade prévia ou grupos de risco, fatores com influência documentada na dinâmica da influenza⁵. A vizinhança é fixa e simétrica, ao contrário das redes de contato reais, que apresentam distribuições heterogêneas de grau e estrutura comunitária. Não são considerados vacinação, tratamento ou intervenções não farmacológicas. Os parâmetros β e γ são constantes ao longo do tempo, sem sazonalidade. Por fim, o horizonte de 350 passos pode ser insuficiente para capturar o comportamento oscilatório de longo prazo do modelo SIS.

Essas escolhas são próprias de um modelo exploratório voltado a avaliar isoladamente o efeito de cada parâmetro em ambiente controlado. Extensões naturais incluem mobilidade via autômatos de gás em rede (*Lattice-Gas CA*), estratificação etária, imunidade parcial e calibração com dados de vigilância (SIVEP-Gripe, WHO FluNet).

Métodos

Autômato celular

A grade toróide $N \times N$ opera com atualização síncrona: todas as células avaliam seu próximo estado a partir dos vizinhos em t e transitam simultaneamente. Condições de contorno periódicas garantem cardinalidade de vizinhança uniforme em toda a grade. São consideradas duas vizinhanças: Von Neumann ($k = 4$, métrica de Manhattan) e Moore ($k = 8$, métrica de Chebyshev).

Regras de transição

O espaço de estados é $Q = \{S, E, I, R\}$, com as seguintes probabilidades de transição por passo:

- **$S \rightarrow I$ (SIR/SIS):** $P = 1 - (1 - \beta)^{k_I}$, com k_I = número de vizinhos infectados
- **$S \rightarrow E$ (SEIR):** mesma fórmula; células expostas não transmitem
- **$E \rightarrow I$ (SEIR):** $P = \sigma$ por passo (latência geométrica, média $1/\sigma$)
- **$I \rightarrow R$ (SIR/SEIR) ou $I \rightarrow S$ (SIS):** $P = \gamma$ por passo (recuperação geométrica, média $1/\gamma$)

Parâmetros de referência para influenza: $\beta = 0,18$, $\gamma = 0,14$ e $\sigma = 0,50^5$.

Implementação

As contagens de vizinhos infectados são obtidas por convolução 2D com `scipy.signal.convolve2d(boundary='wrap')`, eliminando laços Python explícitos. Uma simulação de 300 passos em 80×80 conclui em $\approx 0,04$ s.

Listing 1. Núcleo da regra de atualização (Moore).

```
kernel = np.array([[1,1,1],[1,0,1],[1,1,1]])
n_inf = convolve2d((state == I).astype(np.float32),
                  kernel, mode='same', boundary='wrap')
p_inf = 1.0 - (1.0 - beta) ** n_inf
new_infections = (state == S) & (np.random.random(state.shape) < p_inf)
```

Protocolo Monte Carlo

Cada condição foi executada $n = 30$ vezes com sementes independentes ($seed = 42 + 17r$, $r = 0, \dots, 29$). São reportados média e IC 95% ($\bar{x} \pm 1,96s/\sqrt{n}$) para cada métrica.

Uso de inteligência artificial

O desenvolvimento e a revisão do simulador contaram com auxílio do modelo **Claude Sonnet 4.6** (Anthropic). O histórico completo de prompts utilizado — abrangendo projeto das regras, vetorização, validação Monte Carlo e verificação numérica dos resultados — está arquivado no repositório público.

Disponibilidade de Código

Código-fonte, scripts de experimento, figuras e log de prompts de IA estão disponíveis em:

<https://github.com/alanabclins/Cellular-Automata-and-Epidemiology-Computing>

```
git clone https://github.com/alanabclins/Cellular-Automata-and-Epidemiology-Computing
cd ca-epidemiology/src && python3 main.py --mode all
```

Ambiente: Python 3.10, NumPy 1.24, SciPy 1.11, Matplotlib 3.7, Pandas 2.0.

References

1. Kermack, W. O. & McKendrick, A. G. A contribution to the mathematical theory of epidemics. *Proc. Royal Soc. Lond. A* **115**, 700–721, DOI: 10.1098/rspa.1927.0118 (1927).
2. Keeling, M. J. & Rohani, P. *Modeling Infectious Diseases in Humans and Animals* (Princeton University Press, 2008).
3. Wolfram, S. *A New Kind of Science* (Wolfram Media, 2002).
4. Schiff, J. L. *Cellular Automata: A Discrete View of the World* (Wiley, 2007).
5. Biggerstaff, M., Cauchemez, S., Reed, C., Gambhir, M. & Finelli, L. Estimates of the reproduction number for seasonal, pandemic, and zoonotic influenza: a systematic review of the literature. *BMC Infect. Dis.* **14**, 480, DOI: 10.1186/1471-2334-14-480 (2014).
6. Sirakoulis, G. C., Karafyllidis, I. & Thanailakis, A. A cellular automaton model for the effects of population movement and vaccination on epidemic propagation. *Ecol. Model.* **133**, 209–223, DOI: 10.1016/S0304-3800(00)00294-5 (2000).
7. Fuentes, M. A. & Kuperman, M. N. Cellular automata and epidemiological models with spatial dependence. *Phys. A* **267**, 471–486, DOI: 10.1016/S0378-4371(99)00027-8 (1999).
8. Beauchemin, C., Samuel, J. & Tuszynski, J. A simple cellular automaton model for influenza A viral infections. *J. Theor. Biol.* **232**, 223–234, DOI: 10.1016/j.jtbi.2004.08.001 (2005).
9. White, S. H., del Rey, A. M. & Sánchez, G. R. Modeling epidemics using cellular automata. *Appl. Math. Comput.* **186**, 193–202, DOI: 10.1016/j.amc.2006.06.126 (2007).